Modelado Bicicletas Públicas GCBA

1st María Belén Depalo
Universidad de San Andrés
Buenos Aires, Argentina
mdepalo@udesa.edu.ar

2nd Francesca Giavarini
Universidad de San Andrés
Buenos Aires, Argentina
fgiavarini@udesa.edu.ar

***Resumen*—Se desarrolla un modelo predictivo de arribos en estaciones del sistema de bicicletas públicas del GCBA, utilizando registros históricos de viajes. El enfoque se basa en despachos recientes, sin conocer el destino final del usuario, y busca predecir los arribos mejor que el promedio.**

I. Introducción

Este proyecto presenta el desarrollo de modelos predictivos para estimar la cantidad de arribos de bicicletas en las estaciones del sistema público del Gobierno de la Ciudad de Buenos Aires (GCBA). El objetivo principal es superar la precisión de una predicción basada únicamente en la media histórica. Para ello, se utilizan datos de viajes registrados hasta agosto de 2024, empleando como insumo principal la cantidad de partidas (despachos) desde cada estación en ventanas temporales de 30 minutos, sin conocer el destino final de los usuarios al momento de iniciar el viaje.

II. Conjunto de datos y características

Para la realización de este proyecto, se emplearon los datos disponibles en el conjunto de datos públicos alojado en la Ciudad de Buenos Aires en *data.buenosaires.gob.ar*. Dicho conjunto incluye información sobre los recorridos realizados en el sistema de bicicletas públicas (Ecobici) desde el año 2020 hasta el 2024. Cada registro corresponde a un recorrido completo, desde su punto de origen hasta su destino, e incorpora datos relevantes como las coordenadas de latitud y longitud de las estaciones de inicio y fin, los identificadores únicos de cada estación, el modelo de bicicleta utilizado, entre otros. Se llevó a cabo un preprocesamiento y un análisis exploratorio de los datos, con el objetivo de identificar patrones y características relevantes. En este proceso, se determinaron las estaciones con mayor nivel de actividad. Asimismo, se realizó una clusterización de los arribos a las distintas estaciones según su ubicación geográfica. Además, se examinaron los patrones de arribos considerando diferentes dimensiones temporales, incluyendo el día de la semana, los rangos horarios y la distribución mensual. También, se realizó un análisis de autocorrelación sobre la serie temporal de viajes en un período específico para investigar si existen patrones repetitivos que puedan ser capturados mediante variables de tipo *lag*.

Luego del preprocesamiento, se construyó el dataset relacionado a resolver el problema. Para eso, se utilizaron unicamente los datos más recientes, debido a la extensidad del dataset. Se utilizaron los datos de 2023 y de enero hasta agosto de 2024. El dataset está estructurado en un formato tabular, donde cada fila representa un registro correspondiente a un intervalo de tiempo específico. Se generó una columna por cada estación que registra la cantidad de despachos y otra columna por cada estación que registra la cantidad de arribos. Estas últimas representan las variables objetivo a predecir en el modelo. A estas *features* de despachos, se le sumaron otras generadas en el proceso de preparación de los datos. Se crearon variables derivadas (o *features*) adicionales para enriquecer el análisis y modelado de los patrones de uso del sistema de bicicletas públicas. Estas variables, denominadas `season`, `es_finde` y `nivel_horario`, se generaron a partir de la información temporal disponible en el conjunto de datos, con el propósito de capturar características contextuales relevantes. También se agregaron columnas de *lags* de despachos para todas las estaciones. Las *lags* consisten en incorporar información histórica de la misma variable en intervalos anteriores al tiempo actual. Específicamente, se añadieron columnas que representan el número de despachos registrados en esa misma estación 30 minutos, 1 hora y 1 hora y 30 minutos antes. Estas nuevas variables, como `lag_30min`, `lag_60min` y `lag_90min`, permiten capturar la dependencia temporal del comportamiento del sistema, facilitando así que los modelos identifiquen patrones de uso recurrentes en distintas franjas horarias.

Para capturar la naturaleza cíclica del tiempo dentro del día, se construyó una representación periódica de los bloques horarios. Estas dos nuevas features permiten al modelo capturar relaciones cíclicas entre distintos momentos del día, evitando saltos bruscos entre por ejemplo ‘23:30 y las 00:00‘.

III. Metodología

En el presente trabajo se utilizó el algoritmo **K-means**, una técnica de aprendizaje no supervisado ampliamente usada para la agrupación de datos. Su objetivo es dividir un conjunto de n observaciones en k clústeres, minimizando la varianza intra-clúster. Dado un conjunto de datos $X = \{x_1, x_2, \ldots, x_n\}$, donde $x_i \in \mathbb{R}^d$, se busca encontrar centroides $\{\mu_1, \mu_2, \ldots, \mu_k\}$ que minimicen la función de costo:

$$J = \sum_{i=1}^{n} \sum_{j=1}^{k} \mathbb{I}(c_i = j) \|x_i - \mu_j\|^2$$

donde c_i es el índice del clúster asignado a x_i, y $\mathbb{I}(\cdot)$ es la función indicadora. Para mejorar la estabilidad del algoritmo, se utilizó la variante *K-means++* en la inicialización de los centroides.

También se utilizó el algoritmo **XGBoost** (Extreme Gradient Boosting) para resolver el problema de regresión. XGBoost es una implementación optimizada del método de *gradient boosting*, el cual construye un modelo aditivo basado en árboles de decisión. En cada iteración, se añade un nuevo árbol $f_t(x)$ para minimizar la función de pérdida regularizada:

$$\mathcal{L}^{(t)} = \sum_{i=1}^{n} l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

donde l es una función de pérdida diferenciable, como el error cuadrático medio $l(y, \hat{y}) = (y - \hat{y})^2$, y $\Omega(f)$ es un término de regularización que controla la complejidad del árbol, favoreciendo modelos más simples y generalizables.

IV. Experimentos, Resultados y Discusión

A. Análsis Exploratorio de los Datos

En la imagen 1 se destaca cómo se distribuyen las estaciones geográficamente. Luego, en la imagen 2 se muestra cómo se clusterizaron según la actividad total.

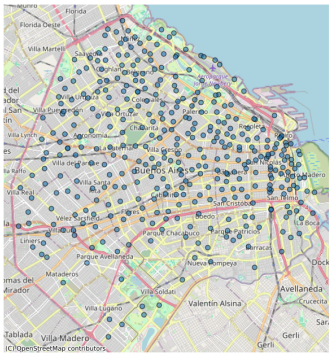

Fig. 1. Distribución geográfica de estaciones Ecobici

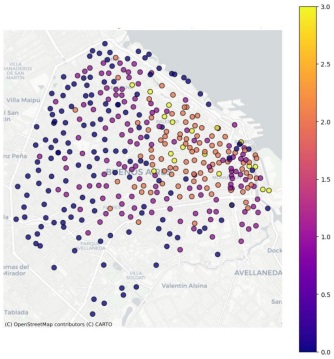

Fig. 2. Clusters según actividad en las estaciones

En la figura 2 se destaca que las estaciones con mayor actividad (indicadas por los colores amarillos y naranjas intensos, que corresponden a valores más altos en la barra de color) se concentran principalmente en el centro de la ciudad de Buenos Aires y se extienden hacia el norte, abarcando áreas como Palermo, Recoleta, Belgrano, y partes de Núñez y Colegiales. Alrededor de los núcleos de alta actividad, se observan estaciones con niveles de actividad moderados (colores anaranjados y morados claros). Estas se extienden hacia barrios como Villa Crespo, Caballito, Almagro, y San Telmo. Las estaciones con menor actividad (colores morados oscuros y azules) se encuentran predominantemente en la periferia de la zona mapeada, en barrios más alejados del centro y posiblemente con menor densidad poblacional o menor flujo de tránsito diario. Ejemplos incluyen Mataderos, Villa Lugano, Villa Riachuelo, y algunas partes del oeste de la ciudad. El conjunto de datos comprende información correspondiente a estaciones con niveles de concurrencia tanto elevados como reducidos. Esta heterogeneidad en la distribución de la actividad impacta negativamente el rendimiento global de los modelos predictivos, cuya especificación se detallará posteriormente. Específicamente, los datos asociados a las estaciones de baja concurrencia introducen un componente de *ruido* que degrada la capacidad de generalización y la precisión predictiva del modelo.

A continuación, en la Tabla I se presenta el ranking de las estaciones con mayor actividad. Estas estaciones se destacan por haber arrojado los mejores resultados en el conjunto de validación al evaluar el desempeño del modelo de predicción de arribos.

Luego, en la Figura 3 se muestra el promedio diario de arribos distribuidos en bloques horarios de 30 minutos. Se observan claramente tres patrones de actividad diferenciados: un bajo volumen de arribos durante la madrugada (entre las 00:00 y las 06:00), un crecimiento gradual desde las 06:30 hasta alcanzar un pico en las horas pico de la tarde (entre las 17:00 y las 19:00), y finalmente una disminución progresiva hacia la noche. Las horas de mayor actividad coinciden con los horarios laborales tradicionales, indicando un uso intensivo del sistema de transporte en esos momentos.

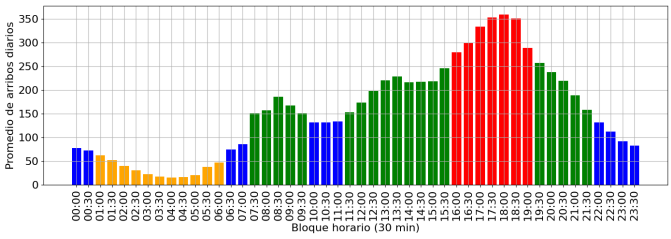

Fig. 3. Clustering de bloques de 30 minutos (promedio diario de arribos)

En la figura 4 se representa la cantidad total de arribos por día de la semana. Se evidencia una alta demanda de lunes a viernes, con valores máximos entre martes y jueves, mientras que los fines de semana (sábado y domingo) presentan una reducción significativa en el número de arribos. Este comportamiento es consistente con un uso predominantemente laboral del sistema, con menor actividad durante los días no laborables. Como se observa en la figura 5, la distribución mensual de los viajes revela una marcada estacionalidad. La cantidad de viajes aumenta significativamente durante la primavera y el verano (de septiembre a marzo), alcanzando sus picos en marzo y noviembre de 2023, y en enero y marzo de 2024. En contraste, la actividad disminuye considerablemente en los meses de invierno (junio, julio y agosto), registrando los valores más bajos del período analizado. Esta tendencia sugiere una clara relación con las estaciones del año, ya que el uso de bicicletas se ve afectado por las condiciones climáticas,

en particular por la menor predisposición a utilizarlas durante los meses más fríos.

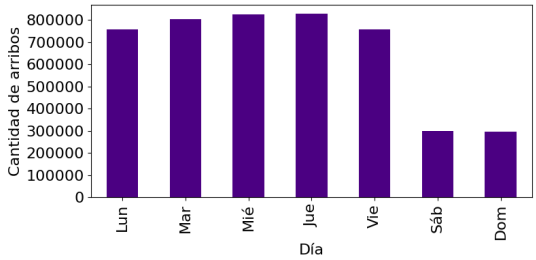

Fig. 4. Arribos por día de la semana

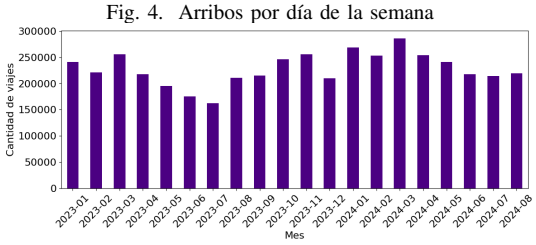

Fig. 5. Enter Caption

Por otro lado, en la figura 6 se ilustra un mapa de calor en el cual se destaca un patrón de actividad distintivo que se correlaciona fuertemente con los hábitos semanales y diarios de los usuarios. Los días hábiles (lunes a viernes) exhiben consistentemente los mayores volúmenes de actividad, marcados por dos picos prominentes: uno en las horas de la mañana, entre las 7:00 y 9:00 AM, que sugiere un uso intenso durante los desplazamientos matutinos; y un segundo y más acentuado pico en las horas de la tarde, particularmente entre las 17:00 y 19:00 PM, reflejando el retorno de actividades laborales o educativas. Por el contrario, los fines de semana (sábado y domingo) muestran una disminución drástica en la actividad general, sin los picos agudos de los días hábiles, y con un uso más distribuido a lo largo de las horas centrales del día (aproximadamente de 10:00 AM a 18:00 PM), indicando un patrón de uso más recreativo. La actividad es mínima durante las horas nocturnas y de madrugada en todos los días de la semana.

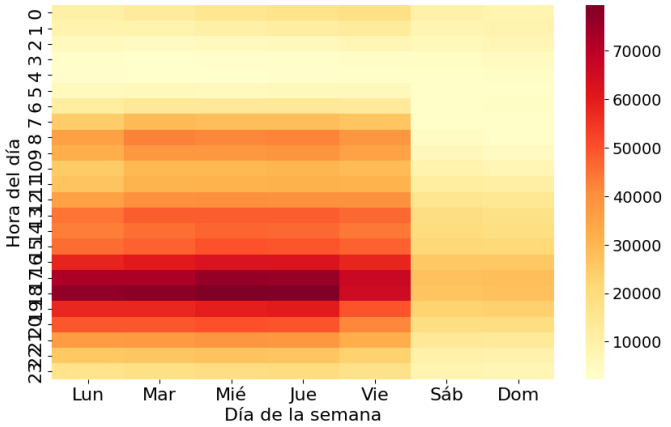

Fig. 6. Mapa de calor: cantidad de arribos por hora y día

Asimismo, los gráficos de las figuras 10, 11 y 12 se incluyen en el Apéndice para complementar el análisis temporal.

Las figuras 10 y 11 muestran representaciones cíclicas de las variables horarias: la primera refleja la continuidad del día (cada punto representa una hora), mientras que la segunda hace lo mismo para los días de la semana. Estas transformaciones permiten que los modelos interpreten correctamente la naturaleza circular del tiempo.

Por su parte, la figura 12 presenta el gráfico de autocorrelación temporal de la serie de arribos. Este análisis permite identificar patrones repetitivos en el tiempo y orientar la selección del número de lags a incluir como features en los modelos predictivos.

B. Modelado

Se desarrollaron y evaluaron diversos modelos con el objetivo de predecir los arribos a las distintas estaciones. Inicialmente, se implementó un modelo base de carácter robusto que consideraba únicamente variables asociadas a los despachos. Posteriormente, se construyeron modelos incrementales incorporando variables temporales, comenzando por características simples como `es_finde` y `season`, y avanzando hacia representaciones más complejas, tales como las transformaciones seno y coseno de los bloques horarios. Finalmente, se incluyeron variables de rezagos (*lags*) de los despachos, tal como fue detallado anteriormente.

Para todos los entrenamientos se utilizó el algoritmo `XGBoost` combinado con `MultiOutputRegressor`, lo que permitió ajustar un modelo por cada estación (o barrio) y predecir múltiples salidas simultáneamente. Esta elección ofreció un buen equilibrio entre precisión y velocidad.

Las métricas obtenidas por cada uno de estos modelos se presentan en la Tabla II. Adicionalmente, se realizó un análisis de desempeño desagregado por estación, cuyos resultados pueden consultarse en el Apéndice.

A partir de la comparación entre modelos, se observa una mejora progresiva al incorporar variables temporales y lags. El modelo más simple, que utiliza únicamente información

de despachos, obtiene un MAE global de 0.4335 y un R^2 de 0.2255. Al añadir variables temporales, especialmente las complejas y aquellas que capturan la estructura horaria, se logra una reducción del error y un aumento en la capacidad explicativa del modelo. La mejor performance se alcanza al incluir lags temporales, lo cual indica que la dinámica pasada de los despachos resulta de gran importancia para predecir los arribos con mayor precisión. También, se dividieron los datos en tres sub-grupos de estaciones: media, alta y baja, haciendo alusión a la actividad en ellas. Los resultados de las métricas para cada estación se pueden observar en la figura 13 del apéndice.

Adicionalmente, se experimentó con el aumento del tamaño de las ventanas temporales de treinta minutos a una hora y dos horas. Los resultados obtenidos para una hora muestran un MAE global de 0.6405 y R^2 global de 0.3588, y para dos horas un MAE global de 0.9416 y un R^2 global de 0.4963. Esto indica un comportamiento mixto. Por un lado, el valor de R^2 mejora notablemente respecto a los modelos anteriores, lo que sugiere una mayor capacidad explicativa del modelo al captar tendencias agregadas en horizontes temporales más amplios. Sin embargo, el MAE aumenta considerablemente, lo cual refleja una pérdida de precisión en la estimación puntual. Esto es esperable, ya que al agrupar la información en ventanas más grandes se suavizan las variaciones, pero también se pierde granularidad. En resumen, ampliar la ventana temporal puede ser útil para análisis más agregados, aunque compromete la exactitud de las predicciones a nivel fino.

Cuando se extiende la ventana temporal a un día completo, los resultados muestran un MAE global de 3.3252 y un R^2 global de 0.7553. Esto indica que, al considerar períodos más largos, el modelo logra capturar con mayor eficacia las tendencias generales del sistema. No obstante, el aumento del MAE refleja nuevamente una pérdida de precisión en las predicciones individuales, dado que el error acumulado por intervalo también crece. En conjunto, estos resultados confirman que existe un trade-off entre granularidad y capacidad predictiva: a medida que se agranda la ventana temporal, se mejora la explicación del comportamiento agregado, pero se sacrifica precisión en términos absolutos.

Además, se llevó a cabo un experimento en el cual, inicialmente, se entrenó un modelo genérico para cada estación utilizando la totalidad de las variables disponibles. El objetivo fue analizar la importancia relativa de cada feature en la predicción de los arribos por estación. A partir de este análisis, se seleccionaron, para cada estación, un subconjunto de a lo sumo 15 variables predictoras que presentaban mayor correlación o relevancia específica para dicha estación.

Posteriormente, se entrenó un nuevo modelo individual para cada estación, restringiendo su entrenamiento exclusivamente a las 15 features seleccionadas previamente para esa estación en particular. Esta estrategia permitió adaptar el conjunto de entradas a las características propias de cada estación, reduciendo el ruido para aquellas estaciones con baja actividad o comportamiento más estable, lo que mejoró significativamente su capacidad de predicción.

Sin embargo, en el caso de las estaciones más activas y complejas, esta selección limitada de variables resultó contraproducente, ya que estos modelos requieren comprender patrones de movilidad más generales e integrados con el sistema completo.

C. Simplificación del problema: Análisis por barrios

Con el objetivo de simplificar la tarea de predicción de arribos y reducir la variabilidad inherente a las estaciones individuales, se propuso una reformulación del problema a nivel de barrios.

Para ello, se asignó a cada estación su correspondiente barrio mediante un cruce espacial entre las coordenadas geográficas de las estaciones y los polígonos administrativos de los barrios porteños. Luego, se reconstruyó el dataset agrupando los despachos y arribos por intervalos de 30 minutos y barrio de origen/destino respectivamente, alineando temporalmente las ventanas de entrada y salida. Este dataset transformado permitió reducir el ruido presente en las estaciones de menor actividad y enfocarse en patrones más globales de movilidad barrial.

Una vez construido el nuevo dataset, se entrenó un modelo individual para cada barrio, comenzando por una versión base con únicamente los despachos como input. Posteriormente, se incorporaron las mismas variables que en los experimentos anteriores, buscando mejorar las métricas de desempeño.

Al analizar la Tabla III (incluida en el Apéndice), se observa que los cinco mejores barrios presentan métricas significativamente superiores respecto a los cinco peores. Esto evidencia que el desempeño del modelo está fuertemente condicionado por la localización geográfica y la dinámica de uso propia de cada zona.

Desagregar el problema a nivel barrial permitió capturar regularidades locales que se pierden en un modelo global. Por ejemplo, ciertos barrios con alta densidad poblacional, mejor infraestructura ciclista o mayor conectividad con centros de trabajo presentaron comportamientos más regulares y predecibles. En contraste, barrios con menor actividad mostraron mayor dificultad para ser modelados con precisión.

D. Evaluación del conjunto de tests

Se evaluó el mejor modelo que predice los arribos cada treinta minutos de cada estación con un conjunto de tests, que incluía los recorridos de el dia 09/09/2024. Los resultados fueron satisfactorios en determinadas estaciones, mientras que en otras no alcanzaron el mismo nivel de desempeño que en el entrenamiento. Esto evidencia una limitación en la capacidad de generalización del modelo, atribuible a que la distribución de los datos futuros no replica exactamente la distribución observada durante el entrenamiento. Esta variabilidad es inherente a la naturaleza estocástica y dinámica de un conjunto de datos de esta magnitud. Las figuras 7, 8 y 9 demuestran estos resultados.

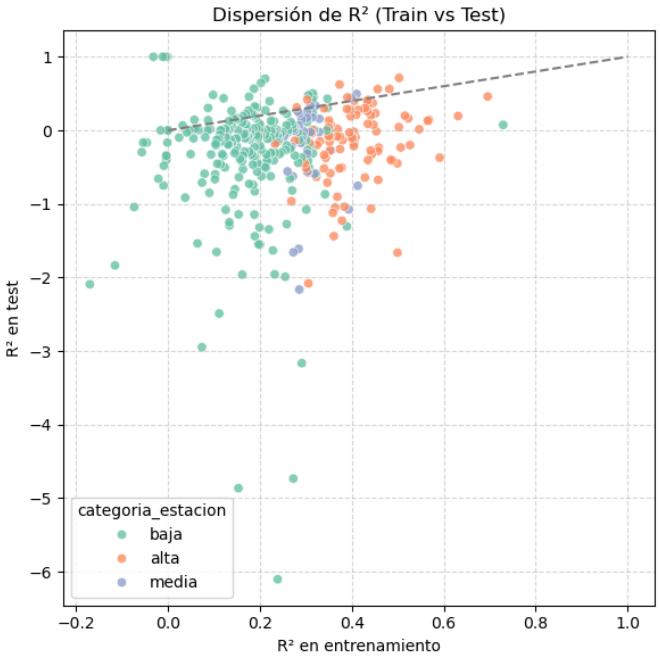

Fig. 7. Dispersión en R² (Train vs Test)

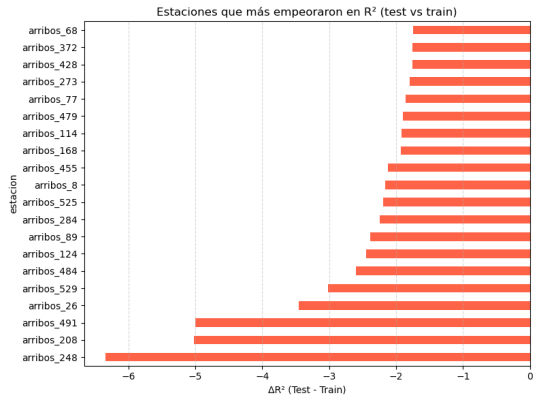

Fig. 8. Estaciones que más empeoraron en R² (test vs train)

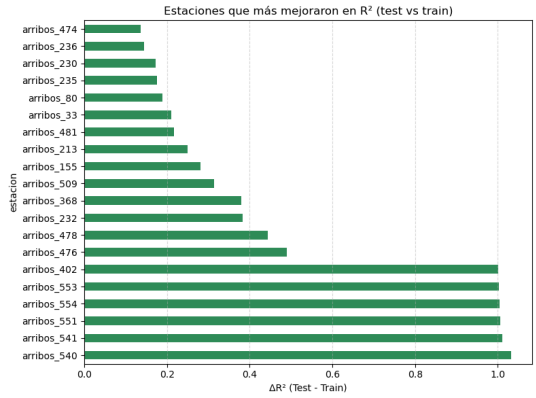

Fig. 9. Estaciones que más mejoraron en R² (test vs train)

En la figura 7 , se observa una tendencia general donde un mayor R² en el entrenamiento se asocia con un mayor R² en la prueba, aunque con una dispersión considerable. Las estaciones de baja categoría muestran una mayor variabilidad en el rendimiento, con muchos puntos concentrados alrededor de R² cero o negativos en la prueba, mientras que las estaciones de alta y media categoría tienden a agruparse en valores de R² más altos y menos dispersos en el conjunto de prueba. Esto sugiere que el modelo tiene dificultades para generalizar el comportamiento de las estaciones con baja actividad. Los graficos 8 y 9, complementan este análisis al identificar las estaciones individuales con los cambios más significativos en el rendimiento del R² entre el entrenamiento y la prueba. El gráfico de mejora muestra que algunas estaciones experimentaron un aumento sustancial en el R² en el conjunto de prueba, con incrementos que superan 0.8 en algunos casos, lo que indica una buena generalización del modelo para estas estaciones. Por otro lado, el gráfico de empeoramiento revela que ciertas estaciones, sufrieron una caída drástica en el R² en el conjunto de prueba, llegando a valores negativos significativos. Esto resalta problemas inherentes en la calidad de los datos para esas estaciones.

También se evaluó el conjunto de test para el modelo predictor por barrios. Los resultados indican que, en los barrios con mayor actividad y volumen de viajes, el modelo logró generalizar adecuadamente, manteniendo valores de R^2 comparables a los obtenidos durante la validación. Por el contrario, en barrios con menor frecuencia de uso, se observó una disminución en el desempeño, lo cual es esperable dado el escaso volumen de datos disponibles para dichas zonas.

Asimismo, se evaluó el desempeño del modelo utilizando conjuntos de prueba para predecir los arribos por estación en ventanas temporales de una y dos horas. Al igual que con las predicciones a 30 minutos, se observó un deterioro en las métricas respecto al conjunto de validación por las mismas causas: ruido aportado por las estaciones con pocos datos debido a la naturaleza estocástica y dinámica de un conjunto de datos de esta magnitud.

V. Conclusion

En este trabajo se presentó el desarrollo de modelos predictivos para estimar la cantidad de arribos de bicicletas en el sistema público del Gobierno de la Ciudad de Buenos Aires, utilizando información histórica de despachos y variables temporales. A partir de una estrategia incremental de modelado, se demostró que la incorporación de variables como estacionalidad, estructura horaria y rezagos temporales permite mejorar sustancialmente la capacidad explicativa del modelo en comparación con un enfoque base.

El análisis de desempeño, tanto global como desagregado por barrio, evidenció que el modelo logra generalizar adecuadamente en zonas con alta actividad, mientras que su rendimiento disminuye en barrios con menor volumen de datos. En estos últimos, se observa una alta variabilidad o “ruido”, lo cual dificulta la capacidad del modelo para aprender patrones consistentes.

Asimismo, se evaluó la capacidad del modelo para predecir arribos en diferentes resoluciones temporales (30 minutos, 1 hora y 2 horas). Se observó que, si bien el error absoluto crece con ventanas más amplias, el modelo tiende a generalizar mejor en esos escenarios, probablemente por el efecto de suavizado que se produce al aumentar el horizonte temporal.

En suma, los resultados obtenidos permiten concluir que es posible construir modelos que, con una complejidad razonable, superen el desempeño de predictores ingenuos. Este tipo de herramientas puede ser valioso para mejorar la planificación logística del sistema, anticipar desequilibrios y optimizar la disponibilidad de bicicletas. A futuro, podrían incorporarse variables contextuales —como condiciones climáticas, eventos especiales o feriados— que influyen directamente en los patrones de movilidad urbana. Asimismo, podría explorarse el uso de modelos más avanzados (por ejemplo, redes neuronales recurrentes o arquitecturas de atención temporal) para capturar mejor la dinámica secuencial de los datos.

Otra línea de trabajo prometedora consiste en agrupar estaciones según similitudes en sus comportamientos (por ejemplo, mediante técnicas de clustering) y entrenar modelos especializados por grupo. Esto permitiría capturar patrones compartidos entre estaciones con dinámicas similares, equilibrando la generalización de un modelo global con la especificidad de los modelos individuales. Además, sería valioso evaluar estrategias de muestreo dirigidas para aquellas estaciones con bajo volumen de datos o difícil comportamiento predictivo. Técnicas como el oversampling, la generación sintética de muestras o el uso de ventanas temporales más flexibles podrían contribuir a mejorar el aprendizaje en estos casos críticos, donde los modelos actuales muestran mayor debilidad.

VI. Apéndice

TABLE I
ESTACIONES CON MAYOR ACTIVIDAD

id_estacion	nombre_estacion	cantidad_arribos	cantidad_partidas
175	147 - Constitución	53980	61993
14	014 - Pacifico	53869	53708
8	008 - Congreso	46141	46123
5	005 - Plaza Italia	45438	45197
202	001 - FACULTAD DE DERECHO	41948	41565
152	152 - JULIETA LANTERI	40232	38115
130	130 - RETIRO II	39646	40395
289	255 - BARRANCAS DE BELGRANO	38449	37847
9	009 - Parque Las Heras	36944	36319
131	131 - HOSPITAL DE CLÍNICAS	36635	37836
54	054 - Acuña de Figueroa	36446	36415
150	150 - RODRIGO BUENO	35223	33731
29	029 - Parque Centenario	32921	33482
128	128 - PARQUE DEL BAJO	32137	33549
277	292 - PLAZA BOLIVIA	31800	31005
516	368 - PLAZA DE LA SHOÁ	31356	31017
161	161 - Humahuaca	30920	31574
111	111 - MACACHA GUEMES	30472	29946
66	066 - Billinghurst	30151	30457

TABLE II
COMPARACIÓN DE MODELOS DE PREDICCIÓN DE ARRIBOS

Modelo	MAE Global	R^2 Global
Solo despachos	0.4335	0.2255
Despachos + Variables temporales simples	0.4295	0.2308
Despachos + Estacionalidad y fin de semana	0.4293	0.2312
Despachos + Temporales complejas + Nivel horario	0.4287	0.2330
Despachos + Temporales complejas + Nivel horario + Lags temporales	0.4256	0.2396
Sacando Features temporales simples (mes, dia, hora, minuto)	0.4261	0.2402

TABLE III
TOP 5 MEJORES Y PEORES BARRIOS SEGÚN R^2

Barrio	**MAE**	**R^2**
	Top 5 Mejores	
arribos_Palermo	4.9275	0.9243
arribos_Recoleta	3.2776	0.8998
arribos_Balvanera	2.8098	0.8578
arribos_Caballito	2.4642	0.8507
arribos_San Nicolas	2.3594	0.8390
	Top 5 Peores	
arribos_Villa Riachuelo	0.0197	-0.0035
arribos_Villa Soldati	0.5083	0.0340
arribos_Villa Lugano	0.7159	0.1540
arribos_Versalles	0.3429	0.1671
arribos_Villa Real	0.4050	0.2178

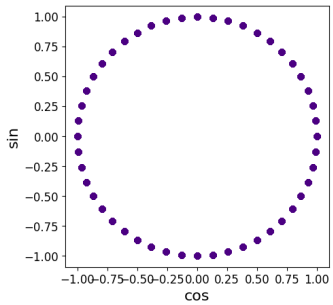

Fig. 10. Representación cíclica del día

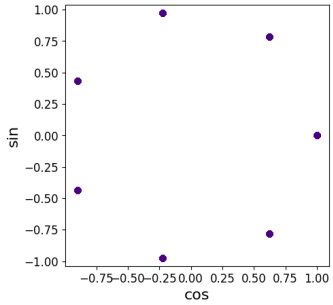

Fig. 11. Representación cíclica del día de la semana

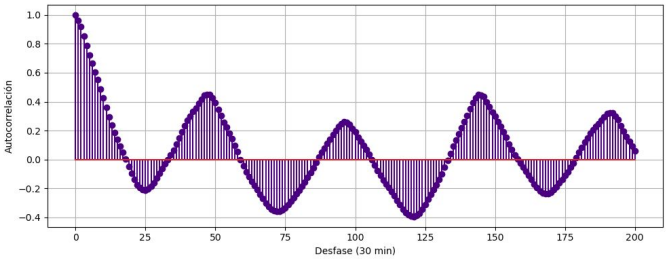

Fig. 12. Autocorrelación lags temporales

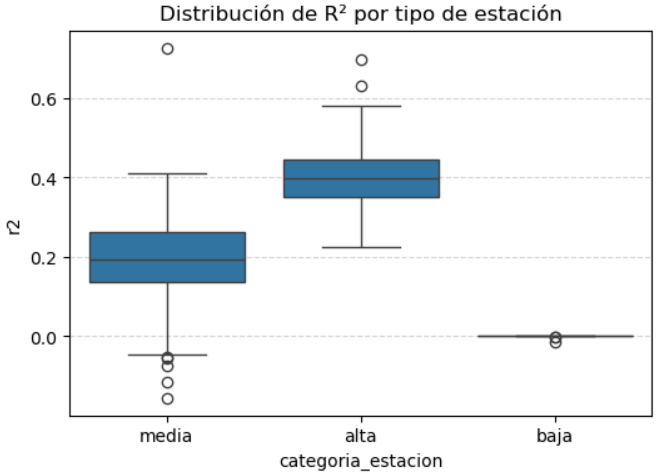

Fig. 13. Distribución de R2 por tipo de estación

VII. REFERENCIAS

1) Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785
2) Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html
3) Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., ... & Zheng, X. (2016). TensorFlow: Large-scale machine learning on heterogeneous systems. *Software available from tensorflow.org*. https://www.tensorflow.org/
4) GeoPandas Development Team. (2023). *GeoPandas: Python tools for geographic data*. https://geopandas.org
5) Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

6) McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 51–56. https://conference.scipy.org/proceedings/scipy2010/pdfs/mckinney.pdf
7) Van Der Walt, S., Colbert, S. C., & Varoquaux, G. (2011). The NumPy Array: A Structure for Efficient Numerical Computation. *Computing in Science & Engineering*, 13(2), 22–30. https://doi.org/10.1109/MCSE.2011.37